

Avance de Proyecto — Predicción de Abandono de Clientes (Customer Churn)

Clasificación binaria — Informe digital

Vicente Alberto Jahrift Alonso López (AL07002967) · Mauricio Flores Frutos (AL02963501)

Materia: Algoritmos de Aprendizaje Automático · Docente: Francisco Gómez Rubio · Actividad: Avance de Proyecto

· Fecha de consulta del dataset: 29 de agosto de 2026

- [1. Definición y delimitación del problema](#)
 - [1.1 Contexto organizacional](#)
 - [1.2 Definición del problema de aprendizaje automático](#)
 - [1.3 Continuidad hacia la entrega final](#)
- [2. Pregunta de análisis](#)
- [3. Descripción y procedencia del dataset](#)
- [4. Diccionario de variables](#)
- [5. Análisis exploratorio de datos](#)
 - [5.1 Estructura general y distribución del objetivo](#)
 - [5.2 Distribución de variables numéricas](#)
 - [5.3 Frecuencia de categorías principales](#)
 - [5.4 Relación de variables con el abandono](#)
 - [5.5 Relaciones entre variables numéricas](#)
- [6. Diagnóstico de calidad de datos](#)
- [7. Revisión de desbalance de clases](#)
- [8. Análisis de fuga de información](#)
- [9. Estrategia de partición](#)
- [10. Pipeline de preprocesamiento](#)
- [11. Modelo baseline](#)
- [12. Comparación de modelos y métricas](#)
 - [12.1 Matrices de confusión](#)
 - [12.2 Curvas ROC](#)
- [13. Optimización de hiperparámetros y validación cruzada](#)
- [14. Análisis de falsos positivos y falsos negativos](#)
- [15. Comparación básica de umbrales](#)
- [16. Selección del modelo preliminar](#)
- [17. Plan de mejora para la entrega final](#)
- [18. Tabla de trazabilidad](#)
- [19. Conclusiones personales](#)

1. Definición y delimitación del problema

1.1 Contexto organizacional

Una institución financiera (banco) ha detectado una disminución en la permanencia de sus clientes. La organización cuenta con registros históricos de antigüedad como cliente, productos contratados, datos demográficos, indicadores de actividad, tipo de tarjeta, puntos acumulados, nivel de satisfacción y si el cliente cerró o no su cuenta.

Necesidad organizacional. Actualmente las acciones de retención se aplican de forma general, sin distinguir qué clientes tienen mayor probabilidad de abandonar. Esto genera un uso ineficiente de los recursos de retención y no prioriza a los clientes de mayor riesgo.

Decisión que se busca apoyar. Estimar, para cada cliente, una probabilidad de abandono que permita priorizar a qué clientes contactar primero con acciones de retención (ofertas personalizadas, contacto proactivo de un ejecutivo de cuenta, mejoras en el servicio).

Por qué debe ser una herramienta de apoyo y no un mecanismo automático. El modelo estima una probabilidad a partir de patrones históricos, no una certeza sobre el comportamiento futuro de una persona en particular. Usar la predicción de forma automática para restringir servicios, modificar

condiciones contractuales o negar beneficios sería un uso indebido: el modelo puede equivocarse (falsos positivos y falsos negativos), puede reflejar sesgos presentes en los datos históricos, y no captura información contextual que sí conoce un ejecutivo humano. El resultado del modelo debe entenderse como **evidencia para priorizar seguimiento**, con la decisión final en manos de un analista o ejecutivo de retención.

1.2 Definición del problema de aprendizaje automático

Elemento	Descripción
Contexto organizacional	Un banco busca priorizar acciones de retención ante una caída en la permanencia de sus clientes.
Unidad de análisis	Cada fila representa a un cliente único del banco.
Variable objetivo	Exited : indica si el cliente abandonó (1) o permanece (0).
Tipo de problema	Clasificación binaria.
Clase positiva	Exited = 1 (cliente que abandona).
Usuarios potenciales	Área de retención de clientes, banca personal, CRM/marketing, gerencia de experiencia del cliente.
Decisión apoyada	Priorizar qué clientes contactar primero con acciones de retención.
Riesgo de uso incorrecto	Tratar la probabilidad como una certeza podría llevar a decisiones injustas sobre clientes que en realidad no iban a abandonar (falso positivo), o a no actuar sobre clientes que sí abandonarán (falso negativo).
Criterio inicial de éxito	Que el modelo supere claramente al baseline trivial y logre un recall razonable sobre la clase de abandono sin sacrificar demasiada precisión.

¿Por qué es clasificación binaria? La variable objetivo **Exited** solo toma dos valores posibles y mutuamente excluyentes (0 = permanece, 1 = abandona), y el objetivo del modelo es asignar cada cliente a una de esas dos clases. La clase positiva se define como el abandono, ya que es el evento que la organización busca anticipar y prevenir.

1.3 Continuidad hacia la entrega final

Este problema —clasificación binaria de abandono de clientes bancarios, con la misma variable objetivo, el mismo dataset y el mismo pipeline reproducible— se mantendrá sin cambios hasta la entrega final del proyecto. Las mejoras planificadas (sección 17) se construirán sobre esta misma base.

2. Pregunta de análisis

¿Cómo pueden utilizarse los datos históricos de los clientes del banco (demográficos, de producto, de actividad y de satisfacción) para identificar los casos con mayor riesgo de abandono y así apoyar, de manera priorizada y reproducible, las acciones de retención del área de clientes?

La pregunta relaciona cuatro elementos: (1) los datos históricos de los clientes, (2) la estimación del riesgo de abandono mediante un modelo de clasificación, (3) el propósito de apoyar —no automatizar— acciones de retención, y (4) la necesidad de que la solución sea reproducible (misma semilla, mismo pipeline, mismas particiones).

3. Descripción y procedencia del dataset

Elemento	Información
Nombre del dataset	Bank Customer Churn (también distribuido como <i>Customer Churn Records</i>)
Fuente	Kaggle — usuario radheshyamkolli para
Liga de acceso	https://www.kaggle.com/datasets/radheshyamkolli/bank-customer-churn
Fecha de consulta	29 de agosto de 2026
Número de observaciones	10,000
Número de variables	18
Formato original del archivo	CSV
Variable objetivo	Exited (1 = el cliente cerró su cuenta / abandonó, 0 = permanece)

Nota sobre el origen del dataset. El dataset originalmente asignado para esta actividad (Telco Customer Churn, BlastChar, Kaggle) fue sustituido por este dataset alternativo debido a una restricción indicada por el docente/tutor sobre el uso del dataset original. Este cambio debe confirmarse formalmente con el docente.

Este dataset cumple las condiciones para un dataset alternativo: variable objetivo binaria de abandono/permanencia, variables numéricas y categóricas, 10,000 registros (suficientes para particiones de entrenamiento, validación y prueba), permite limpieza, codificación y escalamiento, incluye información razonablemente relacionada con la permanencia del cliente (antigüedad, productos, actividad, satisfacción), y tiene una fuente identificable con descripción mínima de variables.

4. Diccionario de variables


Variable	Descripción	Tipo original	Tipo analítico	Rol	Unidad / escala	Faltantes	Tratamiento previsto
RowNumber	Número consecutivo de fila	int	identificador	identificador	1..10000	0	Eliminar
CustomerId	Identificador único del cliente	int	identificador	identificador	único	0	Eliminar
Surname	Apellido del cliente	texto	identificador/texto libre	identificador	texto	0	Eliminar (alta cardinalidad, cuasi-identificador)
CreditScore	Puntaje crediticio del cliente	int	numérica	predictora	~350-850	0	Estandarización
Geography	País de residencia	texto	categórica nominal	predictora	France/Spain/Germany	0	One-Hot Encoding
Gender	Género del cliente	texto	categórica nominal	predictora	Male/Female	0	One-Hot Encoding
Age	Edad del cliente	int	numérica	predictora	años	0	Estandarización
Tenure	Antigüedad como cliente del banco	int	numérica (discreta)	predictora	0-10 años	0	Estandarización
Balance	Saldo en la cuenta	float	numérica	predictora	moneda	0	Estandarización
NumOfProducts	Productos contratados con el banco	int	numérica (discreta) / ordinal	predictora	1-4	0	Estandarización
HasCrCard	Indica si tiene tarjeta de crédito	int (0/1)	binaria	predictora	0/1	0	Se conserva tal cual
IsActiveMember	Indica si es miembro activo	int (0/1)	binaria	predictora	0/1	0	Se conserva tal cual
EstimatedSalary	Salario estimado	float	numérica	predictora	moneda	0	Estandarización
Exited	Indica si el cliente abandonó	int (0/1)	binaria	objetivo	0/1	0	Variable y
Complain	Indica si presentó una queja	int (0/1)	binaria	excluida (fuga)	0/1	0	Excluir — ver sección 8
Satisfaction Score	Puntaje de satisfacción	int	ordinal	predictora	1-5	0	Estandarización
Card Type	Tipo de tarjeta	texto	categórica nominal	predictora	DIAMOND/GOLD/SILVER/PLATINUM	0	One-Hot Encoding
Point Earned	Puntos acumulados	int	numérica	predictora	puntos	0	Estandarización

Variables excluidas del entrenamiento y justificación: - RowNumber, CustomerId: identificadores únicos sin significado analítico. - Surname: dato personal de alta cardinalidad (2,932 valores únicos) sin relación causal razonable con el abandono. - Complain: excluida por **fuga de información** (ver sección 8).

5. Análisis exploratorio de datos

5.1 Estructura general y distribución del objetivo


El dataset tiene 10,000 registros y 18 columnas, sin valores faltantes ni registros duplicados. CustomerId es único por fila, confirmando que cada fila representa a un cliente distinto.



Distribución de la variable objetivo (Exited)

La variable objetivo muestra un desbalance moderado: **79.6%** de los clientes permanece (clase 0) y **20.4%** abandona (clase 1).


5.2 Distribución de variables numéricas



Distribución de variables numéricas relevantes

CreditScore y Age muestran distribuciones aproximadamente simétricas (Age con ligera asimetría hacia edades mayores). Balance muestra un grupo importante de clientes con saldo en cero, razonable en un contexto bancario y no interpretado como error de captura.

5.3 Frecuencia de categorías principales




Frecuencia de categorías principales

5.4 Relación de variables con el abandono




Tasa de abandono por país, actividad y número de productos

Se observa una tasa de abandono notablemente más alta en Geography = Germany frente a Francia y España; los clientes **no activos** muestran mayor abandono que los activos; y los clientes con **3 o 4 productos** contratados muestran una tasa de abandono considerablemente mayor que quienes tienen 1 o 2. Estas son relaciones observadas en los datos históricos, no relaciones causales comprobadas: antes de convertirlas en una conclusión operativa se requeriría un análisis más riguroso, ya que podrían existir factores de confusión no observados.



Age, Balance y CreditScore frente a Exited

5.5 Relaciones entre variables numéricas




Mapa de calor de correlación entre variables numéricas

Ninguna variable numérica muestra una correlación lineal fuerte de forma aislada con Exited, lo que sugiere que la relación es más bien conjunta/no lineal y que se necesitará un modelo —y no solo estadística descriptiva— para capturarla adecuadamente.

Perfiles con mayor proporción de abandono (observación inicial): clientes en Alemania, clientes inactivos, clientes con 3-4 productos contratados y clientes de mayor edad.

6. Diagnóstico de calidad de datos



Boxplots de variables numéricas clave (revisión de atípicos)

Problema detectado	Variable afectada	Evidencia	Posible impacto	Tratamiento propuesto
Valores faltantes	Ninguna	0 nulos en todas las columnas	Ninguno	No se requiere imputación por ausencia de nulos; se incluye igualmente en el pipeline como buena práctica
Registros duplicados	Ninguna	0 duplicados; CustomerId sin duplicados	Ninguno	No se requiere eliminar registros
Categorías inconsistentes / espacios	Geography, Gender, Card Type	Categorías limpias y consistentes	Ninguno	No se requiere limpieza adicional
Columnas numéricas como texto	Ninguna	Todas las numéricas ya son int64/float64	Ninguno	No se requiere conversión
Valores atípicos	CreditScore, Age, Balance	Algunos puntos alejados del rango intercuartílico en los boxplots	Podría afectar a modelos sensibles a escala	Se conservan (son plausibles) y se aplica estandarización
Rangos poco razonables	Ninguna detectada	Age 18-92, CreditScore ~350-850 (plausibles)	Ninguno	No se requiere corrección
Variable con una sola categoría	Ninguna	Todas tienen 2 a 4 categorías	Ninguno	No aplica
Variable con demasiadas categorías	Surname (2,932 valores únicos)	Alta cardinalidad, texto libre	Generaría cientos de columnas sin señal generalizable	Excluir del entrenamiento
Posible fuga de información	Complain	Correlación casi perfecta con Exited (sección 8)	Métricas infladas artificialmente	Excluir del conjunto de predictoras
Desbalance de la variable objetivo	Exited	79.6% / 20.4%	Accuracy puede ser engañosa	Métricas robustas + estratificación

Ningún registro ni variable se elimina sin justificación.

7. Revisión de desbalance de clases

Clase	Conteo	Proporción
0 (permanece)	7,963	79.6%
1 (abandona)	2,037	20.4%

¿Existe desbalance? Sí, un desbalance moderado de aproximadamente 4 a 1.

¿Por qué una accuracy alta puede ser engañosa? Un modelo que prediga siempre “no abandona” alcanzaría cerca de 80% de accuracy sin identificar a ningún cliente en riesgo real (esto se confirma con el baseline, sección 9).

Métricas necesarias. Precision, recall y F1-score de la clase positiva, además de ROC-AUC, ya que reflejan la capacidad real del modelo para distinguir a los clientes que abandonan.

Implicación de no detectar clientes que abandonan (falsos negativos). Cada cliente no detectado

representa una oportunidad de retención perdida y, en consecuencia, una pérdida de ingresos futuros; por eso el **recall** de la clase positiva es especialmente relevante.

¿Por qué no es obligatorio remuestrear en esta fase? Un desbalance de 4 a 1 no es extremo; se optó por usar `class_weight="balanced"` en los modelos que lo permiten, en vez de remuestreo. Si en la fase final se decide aplicar remuestreo (p. ej. SMOTE), debe aplicarse únicamente sobre el conjunto de entrenamiento, nunca sobre prueba ni sobre el dataset completo.

8. Análisis de fuga de información

Se revisó si alguna variable contiene información que solo estaría disponible después del abandono o que revele directa/indirectamente la variable objetivo.

Tabla cruzada Complain vs. Exited (datos reales del dataset):

Complain \ Exited	0	1
0	7,952	4
1	10	2,034

Complain coincide con Exited en **99.86%** de los 10,000 registros.

- **¿Cuándo se genera?** Una queja puede registrarse en cualquier momento, incluyendo el proceso de cancelación de la cuenta.
- **¿Estaría disponible al momento de predecir?** Es dudoso: en un escenario de predicción anticipada del abandono, usar Complain supondría casi conocer ya el desenlace.
- **¿Su uso inflaría artificialmente las métricas?** Sí, de forma severa, dada la correlación casi perfecta observada.
- **Decisión:** se **elimina** Complain del conjunto de variables predictoras.
- **Justificación:** su correlación casi perfecta con la variable objetivo es evidencia fuerte de fuga de información: en vez de ayudar a predecir el abandono, la variable prácticamente ya lo indica.

Otras variables revisadas: CustomerId y RowNumber no representan fuga en sí mismas, pero se excluyen por ser identificadores sin valor predictivo generalizable. Satisfaction Score, Point Earned y Card Type se actualizan de forma continua durante la relación con el cliente, estarían disponibles antes de un eventual abandono, no muestran correlación anómala con Exited, y se **conservan** como predictoras.

Conclusión sobre fuga de información. Se identificó una fuga de información clara en Complain, la cual fue excluida del conjunto de entrenamiento. El resto de las variables conservadas no muestra evidencia de fuga.

9. Estrategia de partición

Se dividió el dataset en entrenamiento (70%), validación (15%) y prueba (15%), con **estratificación** sobre y para conservar la proporción de clases, y una **semilla fija** para garantizar reproducibilidad. El conjunto de prueba se separó desde este punto y no volvió a tocarse (no interviene en la selección del modelo en esta fase).

Parámetro	Valor utilizado
Proporción de entrenamiento	70%
Proporción de validación	15%
Proporción de prueba	15%
Semilla	42
Método de estratificación	<code>stratify=y</code> en ambas divisiones (<code>train_test_split</code> de <code>scikit-learn</code>)

El conjunto de **entrenamiento** se usa para ajustar los modelos; el de **validación**, para compararlos y elegir el modelo preliminar; el de **prueba**, aislado en esta fase, queda reservado para evaluar la generalización final del modelo en la entrega definitiva del proyecto.

Separación de variables predictoras (X, eliminando identificadores y Complain) y variable objetivo (y = Exited, ya codificada como 0/1):

Valor original	Codificación
No abandonó	0
Abandonó	1

10. Pipeline de preprocesamiento

Se usó ColumnTransformer + Pipeline de scikit-learn para que todas las transformaciones se ajustaran **solo** con el conjunto de entrenamiento y luego se aplicaran a validación y prueba, evitando fuga de información durante el preprocesamiento.

- **Variables numéricas** (CreditScore, Age, Tenure, Balance, NumOfProducts, EstimatedSalary, Satisfaction Score, Point Earned): imputación por mediana + estandarización (StandardScaler).
- **Variables binarias** (HasCrCard, IsActiveMember): imputación por si en el futuro aparecieran valores faltantes; se conservan como 0/1.
- **Variables categóricas nominales** (Geography, Gender, Card Type): imputación por categoría más frecuente + codificación One-Hot, con manejo de categorías desconocidas (handle_unknown="ignore").

11. Modelo baseline

Se construyó un DummyClassifier(strategy="most_frequent") (siempre predice la clase mayoritaria) como referencia trivial, evaluado sobre el conjunto de **validación**.

Métrica	Valor
Accuracy	0.796
Recall (clase 1)	0.000
F1-score (clase 1)	0.000

Interpretación. El baseline logra una accuracy alta (cercana a la proporción de la clase mayoritaria) pero un recall de 0: nunca identifica a un cliente en riesgo. Esto confirma que la accuracy por sí sola no es un criterio suficiente, y que cualquier modelo propuesto debe superar claramente este punto de referencia en recall, precision y F1 de la clase positiva. El baseline es indispensable como punto de comparación antes de evaluar modelos más elaborados.

12. Comparación de modelos y métricas

Se entrenaron dos modelos adicionales al baseline, usando el mismo pipeline de preprocesamiento, la misma partición y la misma semilla (42), con configuraciones iniciales razonables (sin búsqueda extensa de hiperparámetros todavía):

Modelo	Configuración
DummyClassifier	strategy="most_frequent"
Regresión logística	max_iter=1000, class_weight="balanced", random_state=42
Árbol de decisión	max_depth=6, class_weight="balanced", random_state=42


Resultados sobre el conjunto de validación (clase positiva = abandono):

Modelo	Accuracy	Precision	Recall	F1-score	ROC-AUC
DummyClassifier	0.796	0.000	0.000	0.000	0.500
Regresión logística	0.713	0.389	0.712	0.503	0.772
Árbol de decisión	0.759	0.444	0.726	0.551	0.818

¿Qué mide cada métrica y por qué importa aquí? - **Accuracy:** proporción total de aciertos; poco informativa dado el desbalance. - **Precision (clase 1):** de los clientes marcados como riesgo, qué proporción realmente abandona. Un exceso de falsos positivos desperdicia recursos de retención. - **Recall (clase 1):** de los clientes que realmente abandonan, qué proporción detecta el modelo. Es la métrica más crítica: un cliente perdido y no detectado representa una oportunidad de retención perdida. - **F1-score:** equilibrio entre precision y recall. - **ROC-AUC:** capacidad de separar ambas clases en distintos umbrales.


Ambos modelos superan claramente al baseline en recall y F1-score, cumpliendo el criterio inicial de éxito definido en la sección 1.2. El árbol de decisión obtuvo un ROC-AUC y un recall ligeramente superiores a los de la regresión logística en esta ejecución; ambos aspectos se retoman en la selección del modelo (sección 16), después de optimizar ambos modelos por validación cruzada (sección 13).

12.1 Matrices de confusión



Matrices de confusión de los tres modelos (validación)

12.2 Curvas ROC



Curvas ROC — regresión logística y árbol de decisión (validación)

13. Optimización de hiperparámetros y validación cruzada

Nota sobre un cambio de alcance respecto al plan original. El ajuste de hiperparámetros y la validación cruzada estaban originalmente planeados como mejoras para la entrega final del proyecto (ver plan de mejora, sección 17). Se decidió **adelantarlos a este avance** para fortalecer la evidencia detrás de la selección del modelo y responder de forma más completa a lo pedido en la actividad, en lugar de dejarlos únicamente como trabajo pendiente.

Se aplicó GridSearchCV con validación cruzada estratificada (StratifiedKFold, 5 folds, semilla fija = 42) **sobre el conjunto de entrenamiento únicamente**, optimizando ROC-AUC como métrica principal de búsqueda por ser independiente del umbral de decisión. El conjunto de validación se mantuvo aparte, para confirmar el desempeño de los mejores hiperparámetros encontrados, y el conjunto de prueba siguió sin tocarse.

Espacios de búsqueda utilizados:

Modelo	Hiperparámetros explorados
Regresión logística	$C \in \{0.01, 0.1, 1, 10, 100\}$
Árbol de decisión	$\text{max_depth} \in \{3, 4, 5, 6, 7, 9, \text{None}\}, \text{min_samples_leaf} \in \{1, 5, 10, 20\}$

Mejores hiperparámetros encontrados:

Modelo	Mejor configuración	ROC-AUC promedio (5-fold, train)
Regresión logística	$C = 0.01$	0.7683
Árbol de decisión	$\text{max_depth} = 6, \text{min_samples_leaf} = 20$	(búsqueda interna del modelo)

Comparación en el conjunto de validación (modelo inicial vs. optimizado):

Modelo	Accuracy	Precision	Recall	F1-score	ROC-AUC
Regresión logística (inicial)	0.7127	0.3886	0.7124	0.5029	0.7723
Regresión logística (optimizada, CV)	0.7160	0.3921	0.7124	0.5058	0.7725
Árbol de decisión (inicial)	0.7587	0.4440	0.7255	0.5509	0.8184
Árbol de decisión (optimizado, CV)	0.7580	0.4436	0.7320	0.5524	0.8210

Interpretación. La validación cruzada da una estimación más estable del desempeño de cada configuración de hiperparámetros, al promediar resultados sobre 5 particiones distintas del conjunto de entrenamiento en lugar de depender de una sola partición de validación que podría no ser representativa. En este caso, la mejora frente a las configuraciones iniciales fue modesta pero consistente en ambos modelos (ligero aumento en F1-score y ROC-AUC), lo cual sugiere que las configuraciones iniciales ya eran razonablemente adecuadas, aunque ahora la elección del modelo preliminar (sección 16) se apoya en evidencia confirmada por validación cruzada y no solo en una comparación con hiperparámetros sin ajustar.

14. Análisis de falsos positivos y falsos negativos

Con el modelo de regresión logística sobre el conjunto de validación (1,500 clientes):

Componente	Valor
Verdaderos negativos (TN)	Clientes que permanecen y el modelo predijo correctamente
Falsos positivos (FP)	Clientes clasificados con riesgo de abandono que realmente permanecen
Falsos negativos (FN)	Clientes clasificados como estables que realmente abandonan
Verdaderos positivos (TP)	Clientes que abandonan y el modelo detectó correctamente

Con un recall de 0.712, el modelo detecta aproximadamente el **71%** de los clientes que realmente abandonan, dejando sin detectar cerca del 29% (falsos negativos).

Costo de cada error: - **Falso positivo:** se invierten recursos de retención (llamadas, ofertas) en un cliente que no los necesitaba. Costo relativamente bajo y recuperable. - **Falso negativo:** se pierde la oportunidad de retener a un cliente; el banco pierde ingresos futuros recurrentes de ese cliente. Costo más alto y no recuperable una vez que el cliente se va.

¿Cuál error es más crítico? El **falso negativo** suele ser más costoso para la organización, por lo que el **recall** de la clase de abandono es la métrica que más de cerca debe vigilarse, sin dejar de monitorear la precisión para no saturar al equipo de retención con demasiados falsos positivos. Esto refuerza por qué la selección del modelo no puede basarse únicamente en accuracy.

15. Comparación básica de umbrales

Se obtuvieron las probabilidades predichas por la regresión logística y se comparó su comportamiento con el umbral predeterminado (0.50) frente a un umbral alternativo más bajo (0.30):

Umbral	Precision	Recall	F1-score	Observación
0.50	0.389	0.712	0.503	Umbral estándar: equilibrio por defecto entre precision y recall
0.30	0.278	0.909	0.426	Umbral más bajo: se marcan más clientes como riesgo → sube el recall, baja la precision

Interpretación. Al bajar el umbral de 0.50 a 0.30, el recall sube de 0.71 a 0.91 (se detectan casi todos los abandonos reales), pero la precisión cae de 0.39 a 0.28 (aumentan considerablemente los falsos positivos). Esto demuestra que la clasificación final depende de una **decisión operativa** —qué tanto está dispuesta la organización a “sobre-contactar” clientes para no perder casos reales— y no únicamente del algoritmo. La selección del umbral definitivo se deja para la fase final, una vez que el área de negocio defina el costo relativo de cada tipo de error.

16. Selección del modelo preliminar

La decisión se basa en los modelos **ya optimizados por validación cruzada** (sección 13), no en las versiones iniciales, ya que representan la mejor configuración encontrada para cada algoritmo.

Criterio	Modelo seleccionado	Justificación
Desempeño general	Regresión logística optimizada	ROC-AUC de 0.7725, confirmado por validación cruzada de 5 folds (no solo una partición), lo que da mayor confianza en la estabilidad del resultado.
Recall de abandono	Ambos modelos optimizados son similares (0.7124 vs 0.7320)	El ajuste de pesos por clase (<code>class_weight="balanced"</code>) favorece la detección de la clase minoritaria en ambos casos.
Equilibrio precision-recall	Árbol de decisión optimizado tiene F1 ligeramente mayor (0.5524 vs 0.5058)	Se reconoce esta ventaja del árbol; no es determinante frente a los criterios de interpretabilidad y estabilidad.
Interpretabilidad	Regresión logística	Sus coeficientes permiten explicar de forma directa qué variables aumentan o disminuyen la probabilidad de abandono, facilitando la comunicación con el área de negocio.
Complejidad	Regresión logística	Modelo simple, rápido de entrenar y de mantener en producción, frente a un árbol que —aun optimizado— conserva más parámetros de estructura.
Riesgo operativo	Regresión logística	Al ser un modelo lineal bien entendido, su comportamiento es más predecible ante nuevos datos que un árbol de decisión, potencialmente más sensible a pequeños cambios en los datos.

Conclusión de la selección. Se elige la **regresión logística optimizada por validación cruzada** ($C = 0.01$, encontrado por GridSearchCV) como modelo preliminar para continuar en la siguiente fase del proyecto. Es importante señalar, con honestidad frente a la evidencia, que el árbol de decisión optimizado obtuvo un ROC-AUC (0.8210 vs 0.7725) y un F1-score (0.5524 vs 0.5058) ligeramente superiores, incluso después de optimizar ambos modelos. Aun así, se prioriza la regresión logística por su interpretabilidad y estabilidad, atributos especialmente valiosos para un modelo que será usado como **apoyo a decisiones humanas** y no como mecanismo automático. A diferencia del avance anterior, esta decisión ya no se apoya en una comparación con hiperparámetros sin ajustar, sino en resultados confirmados mediante 5-fold cross-validation, lo que le da más solidez.

17. Plan de mejora para la entrega final

Nota. El ajuste de hiperparámetros y la validación cruzada, originalmente planeados aquí, ya se implementaron en este mismo avance (sección 13); por eso no aparecen en la tabla de pendientes siguiente.

Área de mejora	Acción propuesta	Limitación que atiende
Modelos avanzados	Comparar Random Forest, Gradient Boosting (XGBoost/LightGBM) y SVM	Los modelos actuales (regresión logística y árbol de decisión) son relativamente simples; modelos de ensamble podrían capturar mejor interacciones no lineales
Selección de características	Analizar importancia de variables y probar eliminación recursiva	Podría simplificarse el modelo sin perder desempeño
Interpretabilidad	Aplicar SHAP o LIME sobre el modelo final	Permitiría explicar predicciones individuales al equipo de retención
Revisión de sesgos/subgrupos	Comparar métricas por Geography y Gender	Ya se observó una tasa de abandono distinta por país; debe verificarse que el modelo no discrimine en desempeño

Serialización del pipeline	Guardar el pipeline completo con <code>joblib</code>	Permite reutilizar el modelo sin reentrenar y facilita el despliegue
Mecanismo de inferencia	Construir una función/endpoint que reciba datos de un cliente nuevo y regrese la probabilidad de abandono	Actualmente el modelo solo se evalúa sobre datos históricos
Monitoreo	Definir métricas a vigilar en producción (drift de datos, recall en el tiempo) y frecuencia de reentrenamiento	El desempeño puede degradarse con el tiempo

Cada mejora responde directamente a una limitación identificada en este avance: modelos simples sin optimizar, una sola partición de validación, ausencia de análisis de subgrupos, y falta de un mecanismo para llevar el modelo a un entorno operativo.

18. Tabla de trazabilidad

Elemento	Detalle
Dataset	Bank Customer Churn (Customer Churn Records), 10,000 registros, 18 variables
Fuente	Kaggle — usuario <code>radheshyamkollipara</code>
Fecha de consulta	29 de agosto de 2026
Semilla	42 (usada en todas las particiones y modelos)
Pipeline	<code>ColumnTransformer</code> (imputación + escalamiento numérico, imputación binaria, imputación + One-Hot categórico) dentro de un <code>Pipeline</code> de <code>scikit-learn</code>
Baseline	<code>DummyClassifier(strategy="most_frequent")</code>
Modelos comparados	Regresión logística y Árbol de decisión, cada uno en versión inicial y versión optimizada por <code>GridSearchCV</code> (<code>C=0.01</code> para regresión logística; <code>max_depth=6</code> , <code>min_samples_leaf=20</code> para el árbol)
Validación cruzada	<code>StratifiedKFold(n_splits=5, shuffle=True, random_state=42)</code> sobre el conjunto de entrenamiento, optimizando ROC-AUC
Métricas	Accuracy, Precision, Recall, F1-score, ROC-AUC, matriz de confusión, curva ROC
Entorno de ejecución	Google Colab / Python 3 (Pandas, NumPy, Scikit-learn — versiones registradas en el notebook)
Archivo principal	<code>proyecto_churn_notebook.ipynb</code>
Fecha de ejecución	Registrada automáticamente en la última celda del notebook

19. Conclusiones personales

(Esta sección debe personalizarse con la reflexión propia del estudiante; se incluye un borrador integrador que cubre los elementos requeridos y puede ajustarse en tono y extensión.)

Este avance de proyecto abordó el problema de anticipar el abandono de clientes de un banco mediante un modelo de clasificación binaria, con el fin de apoyar —no automatizar— las decisiones del área de retención. Entre las decisiones más relevantes del proceso destacan: la sustitución del dataset original por uno alternativo (Bank Customer Churn) ante una restricción del docente, la exclusión de la variable `Complain` por presentar una fuga de información evidente (99.86% de coincidencia con la variable objetivo), el uso de estratificación y semilla fija en la partición de datos, la elección de `class_weight="balanced"` para atender el desbalance de clases sin recurrir a remuestreo en esta fase, y la decisión de **adelantar el ajuste de hiperparámetros y la validación cruzada a este mismo avance** (sección 13) en lugar de dejarlos únicamente como trabajo pendiente para la entrega final.

En cuanto al desempeño, tanto la regresión logística como el árbol de decisión superaron claramente al baseline trivial (recall de 0 en el baseline frente a 0.71-0.73 en los modelos entrenados), cumpliendo el criterio de éxito planteado al inicio del proyecto. Tras optimizar ambos modelos con `GridSearchCV` y validación cruzada de 5 folds, la mejora frente a las configuraciones iniciales fue modesta pero consistente. Se seleccionó la regresión logística optimizada como modelo preliminar por su interpretabilidad y estabilidad, aun reconociendo —con la misma honestidad que en el avance anterior— que el árbol de decisión optimizado mostró un ROC-AUC y F1-score ligeramente superiores.

Entre las limitaciones identificadas se encuentran: la falta de un análisis de desempeño diferenciado por subgrupos (por ejemplo, por país, donde ya se observó una tasa de abandono distinta), la ausencia todavía

de una comparación contra modelos de ensamble (Random Forest, Gradient Boosting), y que el umbral de decisión sigue sin definirse de forma operativa junto con el área de negocio.

Antes de considerar este modelo como una solución operativa, es necesario: comparar modelos de ensamble adicionales, definir el umbral de decisión junto con el área de negocio considerando el costo relativo de cada tipo de error, revisar posibles sesgos por subgrupo, serializar el pipeline completo, y establecer un mecanismo de inferencia junto con un plan de monitoreo en producción — acciones todas detalladas en el plan de mejora de la sección 17.

Nota importante. Este modelo es una herramienta de apoyo a la toma de decisiones del área de retención. Sus resultados no deben interpretarse como una certeza sobre el comportamiento futuro de un cliente en particular, ni deben usarse de forma automática para restringir servicios, modificar contratos o tomar decisiones desfavorables sobre un cliente sin la intervención de un analista humano.